

Propuesta de Especialización Maestra: Análisis Integral del Cambio Climático y Retroceso Glaciar

Este documento detalla un plan de implementación académico paso a paso que fusiona los objetivos del análisis del cambio climático y el monitoreo del retroceso glaciar. El plan de estudios aprovecha **ArcGIS Pro**, **ENVI**, **RStudio** y entornos **Python** para crear un pipeline analítico robusto de extremo a extremo.

Basado en un perfil avanzado, esta especialización incluye **PyTorch**, vías analíticas duales **Python/R**, sensores adicionales (Sentinel-1 SAR, MODIS), integración de Machine Learning y un **flujo de trabajo principal en Python puro con Google Earth Engine (GEE) como alternativa**.

Si bien el proceso de aprendizaje se divide en **Capítulos** académicos, el objetivo final es sintetizar todas las técnicas en un **proyecto masivo y unificado**.

Resumen de Recursos y Técnicas

Recursos de Datos:

- **Sensores Ópticos:** Landsat (5, 7, 8, 9) y Sentinel-2.
- **Sensores de Radar:** Sentinel-1 SAR.
- **Sensores Termales/Gruesos:** MODIS.
- **Datasets Climáticos:** WorldClim, CHIRPS.
- **Datos In-Situ:** Estaciones meteorológicas locales (ej. CR2 Chile, Meteostat).

Técnicas Analíticas:

- **Deep Learning (PyTorch):** Redes Neuronales Convolucionales (CNN) U-Net para la segmentación automática de lagunas glaciares.
- **Machine Learning (scikit-learn/XGBoost):** Interpolación espacial de registros de estaciones meteorológicas.
- **Modelado de Nichos Ecológicos (SDM):** Máxima Entropía (MaxEnt) en R (**dismo**) y Python (**elapid**).
- **Procesamiento Avanzado de Imágenes:** Corrección Radiométrica y Atmosférica.
- **Evaluación Multicriterio (MCE):** Modelado de superposición ponderada.
- **Procesamiento Cloud-Native y Alternativo:** STAC/**xarray** (Principal) y API de GEE (Alternativa).

Región de Interés (ROI) Seleccionada

Parque Nacional Torres del Paine y Punta Arenas, Región de Magallanes, Chile.

- **Glaciología y Ecosistemas (Torres del Paine):** Retroceso glaciar (Glaciar Grey), lagunas (NDWI), cobertura de nieve (NDSI) y nichos ecológicos.
 - **Clima Urbano y Meteorología (Punta Arenas / Estaciones Regionales):** Modelos de Islas de Calor Urbanas (UHI) e interpolaciones de Machine Learning en datos de estaciones meteorológicas.
-

Estructura Detallada del Proyecto y Flujo Académico

CAPÍTULO 1: Variables Climáticas, Procesamiento de Imágenes y Machine Learning

Objetivo Académico: Establecer una base en la adquisición de datos, corrección atmosférica y modelado climático. Aprenderá a manejar datos del mundo real (como registros meteorológicos incompletos) y a transformar imágenes satelitales en Datos Listos para el Análisis (ARD).

Chapter_01/01_roi_and_acquisition/

- **Concepto:** Comprender cómo buscar y descargar programáticamente datos geoespaciales sin clics manuales.
- **primary_stac_download.py:** Utiliza la API de Copernicus Data Space y los catálogos AWS STAC. *Salida:* Archivos GeoTIFF sin procesar descargados localmente o en una máquina virtual en la nube.
- **alternative_gee_download.py:** Utiliza la librería **geemap** de Python para consultar los mismos datos a través de los servidores de Google, demostrando una alternativa más rápida y sin infraestructura.

Chapter_01/02_envi_and_python_correction.py

- **Concepto:** Las imágenes satelitales contienen dispersión atmosférica (bruma). Aprenderá la física detrás de la conversión de la reflectancia del Tope de la Atmósfera (TOA) a la reflectancia de la Base de la Atmósfera (BOA).
- **Acción:** Proporcionamos documentación para la corrección estándar de ENVI (FLAASH) y escribimos un script en Python (**rasterio**, **Py6S**) que replica esto matemáticamente, asegurando que sus datos ópticos estén limpios antes de pasarlos a modelos de IA.

Chapter_01/03_station_data_interpolation.py

- **Concepto:** Las estaciones meteorológicas suelen tener vacíos de datos. Usamos Machine Learning para predecir valores faltantes en función de la topografía circundante.
- **Acción:** Un script que entrena un modelo Random Forest / XGBoost sobre datos de estaciones conocidas (elevación, latitud, temperatura) para interpolar espacialmente un mapa ráster continuo del clima local sobre Punta Arenas.

Chapter_01/04_precipitation_dual_analysis/

- **Concepto:** Ciencia de Datos Comparativa. ¿En qué se diferencian R y Python al analizar la misma serie temporal ráster (precipitación CHIRPS)?
- **analysis.R & analysis.py:** Scripts que calculan anomalías históricas de precipitación (sequías/inundaciones).
- **unsupervised_classification.py:** Un script de ArcGIS Pro que utiliza agrupamiento no supervisado (IsoCluster) para agrupar automáticamente regiones con climas históricos similares.

Chapter_01/05_urban_heat_islands_modis.py

- **Concepto:** La urbanización altera los microclimas. Aprenderá a convertir la radiancia termal de Landsat/MODIS en Temperatura de la Superficie Terrestre (LST) en grados Celsius para mapear el efecto de Isla de Calor Urbana en Punta Arenas.

CAPÍTULO 2: Retroceso Glaciar, Dinámica SAR e IA (PyTorch)

Objetivo Académico: Transición de datos climáticos generales a glaciología especializada. Aprenderá a rastrear la pérdida de hielo utilizando enfoques multisensor (Radar y Óptico) y a aplicar Deep Learning de última generación para la extracción automatizada de características.

Chapter_02/01_area_perimeter_changes.py

- **Concepto:** Análisis vectorial SIG tradicional.
- **Acción:** Uso de ArcGIS Pro y Python para calcular los kilómetros cuadrados exactos de hielo perdido en el frente del Glaciar Grey durante los últimos 30 años.

Chapter_02/02_sentinel1_sar_analysis.py

- **Concepto:** La región de la Patagonia es extremadamente nubosa, lo que hace que los sensores ópticos (Landsat) sean inútiles durante meses. El Radar de Apertura Sintética (SAR) penetra las nubes.
- **Acción:** Un script en Python puro (`xarray`, API de ASF) que analiza la retrodispersión de Sentinel-1 para diferenciar entre nieve seca, nieve húmeda y hielo sólido, permitiendo un monitoreo continuo independientemente del clima.

Chapter_02/03_ndwi_multitemporal/

- **Concepto:** El Índice Diferencial de Agua Normalizado (NDWI) explota la absorción de luz infrarroja cercana por el agua para mapear la expansión de la Laguna Grey proglaciar.
- **primary_xarray_ndwi.py & alternative_gee_ndwi.py:** Implementación del cálculo del índice espectral utilizando las vías de Python puro y la alternativa de GEE.

Chapter_02/04_pytorch_lake_segmentation.py

- **Concepto:** Más allá de los índices espectrales simples. Segmentación Semántica usando Deep Learning.
- **Acción:** Construiremos una Red Neuronal Convolucional (CNN) U-Net en **PyTorch**. La red aprende las características espaciales y contextuales de los lagos glaciares, segmentando el lago del hielo con mucha más precisión que el NDWI. *Salida:* Un shapefile del límite del lago generado por IA.

Chapter_02/05_ndsi_arcpy_model.py

- **Concepto:** Mapeo de la extensión de la cobertura de nieve usando el Índice Diferencial de Nieve Normalizado (NDSI).
- **Acción:** Script automatizado de ArcGIS Pro para rastrear las líneas de nieve estacionales en las montañas circundantes.

CAPÍTULO 3: Vulnerabilidad e Impactos en los Ecosistemas

Objetivo Académico: Comprender las consecuencias biológicas y humanas de los cambios físicos mapeados en los Capítulos 1 y 2.

Chapter_03/01_maxent_modeling/

- **Concepto:** Modelado de Distribución de Especies (SDM). Si la temperatura aumenta y la precipitación disminuye, ¿hacia dónde migrará la flora/fauna nativa?

- **maxent_modeling.R & maxent_modeling.py:** Utilizamos el algoritmo de Máxima Entropía (MaxEnt), combinando datos de presencia de especies con proyecciones futuras de WorldClim (ej. año 2050) para mapear nichos ecológicos futuros.

Chapter_03/02_vulnerability_index_mce.py

- **Concepto:** Toma de decisiones espaciales.
 - **Acción:** Combinamos todos los resultados anteriores (Anomalías de precipitación, Islas de Calor, Pérdida de hielo glaciar y Cambios ecológicos) en una única matriz de Evaluación Multicriterio (MCE) en ArcGIS Pro. *Salida:* Un "Mapa de Calor de Vulnerabilidad Climática" final que identifica las zonas de mayor riesgo.
-

CAPÍTULO 4: Cartografía Final y Automatización

Objetivo Académico: Comunicar datos espaciales complejos de manera clara a los responsables políticos y partes interesadas.

Chapter_04/01_map_automation_arcgis_python.py

- **Concepto:** Diseño cartográfico y automatización.
 - **Acción:** Un script (`arcpy.mp` o `matplotlib/cartopy`) que genera automáticamente mapas en PDF estandarizados y listos para publicación. Inserta las capas de vulnerabilidad, añade leyendas dinámicas, superpone los límites del lago de PyTorch e incrusta gráficos de series temporales generados en el Capítulo 1.
-

CAPÍTULO 5: Proyecto Capstone - El Pipeline Unificado

Objetivo Académico: Elevar al estudiante de "ejecutor de scripts" a "constructor de sistemas geoespaciales de nivel empresarial". Este capítulo toma todos los scripts modulares y educativos de los Capítulos 1 al 4 y los une en un orquestador masivo y automatizado.

Chapter_05/main_pipeline.py (El Orquestador)

- **Cómo funciona:** Ejecutará este único script en Python. Leerá un archivo de configuración (ej. definiendo el año y el ROI) y ejecutará autónomamente todo el flujo:
 1. **Ingesta de Datos:** Llama a los scripts del Capítulo 1 para descargar las últimas imágenes de Sentinel/Landsat y datos meteorológicos.
 2. **Preprocesamiento:** Llama a los scripts de corrección atmosférica e interpolación ML para limpiar los datos.
 3. **Análisis e IA:** Alimenta la imagerie limpia al modelo PyTorch (Capítulo 2) para extraer el límite actual de la laguna glaciar, y ejecuta los scripts SAR para verificar el estado del hielo.
 4. **Actualización de Vulnerabilidad:** Pasa los nuevos datos a los modelos MCE y de Nicho Ecológico (Capítulo 3) para actualizar el índice de vulnerabilidad.
 5. **Reportes:** Finalmente, activa el módulo de Cartografía (Capítulo 4) para producir un informe en PDF formateado y un mapa del estado actual del clima/glaciar.
- **Resultado:** Un proyecto masivo y unificado que demuestra un entendimiento a nivel de maestría de IA aplicada, SIG y Ciencia Climática.

Plan de Verificación

1. **Pruebas de Integración del Pipeline:** Verificar que los datos fluyan sin problemas desde el módulo de descarga en el Capítulo 1 hasta el módulo de cartografía en el Capítulo 4 cuando son activados por el orquestador `main_pipeline.py`.
2. **Pruebas del Framework de IA:** Validar el modelo U-Net de PyTorch mediante métricas de Intersección sobre Unión (IoU) frente a etiquetas manuales.
3. **Interpolación de Machine Learning:** Realizar validación cruzada (K-Fold) en los modelos de estaciones meteorológicas Random Forest/XGBoost.
4. **Validación SAR vs Óptico:** Comparar los límites SAR de Sentinel-1 contra los datos ópticos de Sentinel-2 (NDSI).